

Chủ đề 1: Linear Regression

Bài 1: Cho tập dữ liệu quan sát về số năm kinh nghiệm x và mức lương (y - đơn vị: triệu đồng) của 4 kỹ sư như sau:

- 1,10 , 2,15 , 3,18 , 4,25

1. Tính các giá trị trung bình $\bar{x}$ và $\bar{y}$.
2. Tìm phương trình hồi quy tuyến tính dạng $y = w_1x + w_0$ bằng cách tính trực tiếp các hệ số theo công thức:

$$w_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

$$w_0 = \bar{y} - w_1\bar{x}$$

3. Dự báo mức lương của một kỹ sư có 5 năm kinh nghiệm.

Bài 2: Sử dụng mô hình tìm được ở **Bài 1**:

1. Tính giá trị dự báo $\hat{y}_i$ cho từng điểm dữ liệu $x_i \in \{1,2,3,4\}$.
2. Tính tổng bình phương sai số thặng dư (SSE - Sum of Squared Errors).
3. Tính hệ số xác định R^2 biết rằng tổng bình phương tổng thể ($SST = \sum (y_i - \bar{y})^2$) của tập dữ liệu này là 115. Giải thích ý nghĩa của con số R^2 tìm được.

Bài 3: Cho bài toán hồi quy đa biến với ma trận đặc trưng X (đã thêm cột bias bằng 1) và vector mục tiêu y :

$$X = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \quad y = \begin{bmatrix} 1 \\ 3 \\ 4 \end{bmatrix}$$

Sử dụng công thức **Normal Equation**: $w = (X^T X)^{-1} X^T y$ để tìm vector trọng số $w = [w_0, w_1]^T$.

Bài 4: Giả sử ta có hàm mất mát (Loss function) cho một tham số là: $J(w) = 3w - 6w^2$.

Ta muốn tìm w để $J(w)$ nhỏ nhất bằng thuật toán Gradient Descent.

1. Tính đạo hàm (Gradient) $\frac{dJ}{dw}$.
2. Giả sử giá trị khởi tạo $w^0 = 0$ và tốc độ học (learning rate) $\eta = 0.05$. Hãy tính giá trị của w sau 2 bước cập nhật (w^1 và w^2).
3. Giá trị w sẽ hội tụ về bao nhiêu nếu số bước lặp tiến đến vô cùng?

Bài 5: Một kỹ sư đang xây dựng mô hình dự báo giá nhà dựa trên diện tích (x_1 tính theo m^2 , khoảng 50 – 500) và số phòng ngủ (x_2 , khoảng 1 – 5).

1. Tại sao việc sử dụng trực tiếp dữ liệu này vào Gradient Descent có thể khiến thuật toán hội tụ rất chậm?
2. Hãy thực hiện chuẩn hóa dữ liệu (Standardization/Z-score Normalization) cho điểm dữ liệu có diện tích $x = 100m^2$. Biết rằng trong tập dữ liệu, diện tích trung bình $\mu = 150m^2$ và độ lệch chuẩn $\sigma = 50m^2$. Công thức: $z = \frac{x-\mu}{\sigma}$.

Bài 6: Trong môi trường công nghiệp, cảm biến nhiệt độ PT100 có thể gặp nhiễu đột biến (outliers) do can nhiễu điện từ từ động cơ. Ta có tập dữ liệu ADC đọc về (x) và nhiệt độ thực tế (y).

Giả sử tại một thời điểm, dữ liệu bị nhiễu nặng: $x = [10, 20, 30, 100]$, $y = [15, 25, 35, 200]$ (điểm cuối là nhiễu).

1. Nếu dùng **MSE**, sai số tại điểm nhiễu $100 - 200^2 = 10000$ sẽ ảnh hưởng thế nào đến đường hồi quy?
2. Tại sao việc áp dụng **Huber Loss** với ngưỡng $\delta = 1.0$ lại giúp đường hồi quy bền vững hơn trước điểm nhiễu $y = 200$?

Bài 7: Bạn đang phát triển một thiết bị Edge AI chạy pin. Mức tiêu thụ dòng điện (y) phụ thuộc vào xung nhịp CPU (x_1), số lượng nhân NPU hoạt động (x_2) và độ sáng màn hình (x_3). Do thiết kế phần cứng, x_1 và x_2 có tương quan rất mạnh với nhau.

1. Tại sao khi sử dụng OLS thông thường, các hệ số trọng số w_1, w_2 có thể trở nên rất lớn và mất ổn định?

2. Nếu thêm thành phần chính quy hóa L2 ($\lambda \sum w_j^2$), hãy giải thích cơ chế giúp ma trận $X^T X + \lambda I$ luôn có thể nghịch đảo được, từ đó ổn định hệ số hồi quy.
3. Nếu bạn muốn hy sinh một chút độ chính xác trên tập training để mô hình hoạt động ổn định hơn trên các thiết bị phần cứng khác nhau (Generalization), bạn sẽ tăng hay giảm λ ?


Bài 8: Một bo mạch giám sát sức khỏe động cơ thu thập 10 loại tín hiệu khác nhau (rung động, âm thanh, từ trường, nhiệt độ...). Tuy nhiên, tài nguyên tính toán của MCU có hạn, bạn chỉ muốn chọn ra 3-4 đặc trưng quan trọng nhất để chạy mô hình dự báo lỗi.

1. Giải thích tại sao khi tăng tham số phạt λ trong Lasso, các hệ số w của các đặc trưng ít quan trọng sẽ bị triệt tiêu về đúng bằng 0.
2. So sánh ưu điểm của Lasso so với việc dùng tay thử sai từng tổ hợp biến trong bài toán có rất nhiều cảm biến đầu vào.

Bài 9: Bạn đang làm hệ thống Adaptive GPS weighting cho robot. Mô hình Multilayer Perceptron (hoặc Linear Regression bậc cao) của bạn đạt sai số gần như bằng 0 trên tập dữ liệu đã thu thập ở văn phòng, nhưng khi đem ra thực địa (đường phố nhiều nhà cao tầng), sai số lại nhảy vọt.

1. Đây là hiện tượng High Bias hay High Variance?
2. Đề xuất 2 giải pháp kỹ thuật để khắc phục.


Bài 10: Giả sử bạn đang huấn luyện một mô hình hồi quy để dự báo nhiệt độ của một chip vi điều khiển dựa trên xung nhịp CPU và điện áp cấp. Đồ thị dưới đây biểu diễn giá trị hàm mất mát (Loss - tính bằng MSE) trên tập Training (màu xanh) và tập Validation (màu cam) sau 100 kỷ nguyên (Epochs).



Dựa trên đồ thị, hãy trả lời các câu hỏi sau:

1. Quan sát hình dáng của hai đường cong. Tại sao Training Loss tiếp tục giảm về gần 0 trong khi Validation Loss bắt đầu tăng lại sau Epoch thứ 40? Hiện tượng này gọi là gì và giải thích cơ chế của nó?
2. Trong bối cảnh triển khai mô hình lên hệ thống nhưng có tài nguyên hạn chế, bạn sẽ chọn phiên bản mô hình ở Epoch nào (ví dụ: Epoch 20, Epoch 40, hay Epoch 80) để nạp vào chip? Giải thích lựa chọn của bạn dựa trên yêu cầu về độ chính xác và khả năng tổng quát hóa (generalization).
3. Đề xuất ít nhất hai giải pháp kỹ thuật (về dữ liệu hoặc tham số) để giúp hai đường cong này nằm sát nhau hơn trong các lần huấn luyện sau.


Bài 11: Một kỹ sư nhúng khác đang hiệu chuẩn cảm biến gia tốc (accelerometer) bằng Gradient Descent. Đồ thị dưới đây so sánh diễn biến của hàm mất mát (Loss) theo số bước lặp (Iterations) dưới 3 kịch bản khác nhau của Learning Rate η .



Dựa trên đồ thị, hãy trả lời các câu hỏi sau:

1. Quan sát Đường cong A (màu xanh lá cây) và Đường cong B (màu cam). Giải thích tại sao đường A giảm rất chậm trong khi đường B lại dao động mạnh (oscillation) và cuối cùng Loss tăng vọt lên vô cùng (diverge)?
2. Kết nối các đường cong với Learning Rate phù hợp: Đường nào tương ứng với Learning Rate quá nhỏ? Đường nào tương ứng với Learning Rate quá lớn? Và đường nào là Learning Rate tối ưu? Nêu lý do cho từng lựa chọn.
3. Nếu bạn muốn triển khai tính năng Tự động điều chỉnh Tốc độ học (Auto-tuning), bạn sẽ dựa vào tín hiệu nào từ đồ thị Loss để quyết định giảm Tốc độ học? Đề xuất một giải mã (pseudocode) ngắn gọn cho logic này.

Bài 12: Bạn đang xây dựng một mô hình MLP phức tạp để dự báo độ chính xác của GPS dựa trên số lượng vệ tinh, cường độ tín hiệu và độ cao. Đồ thị dưới đây mô tả sai số (Error) trên tập Training (xanh) và tập Validation (cam) khi thay đổi Kích thước tập dữ liệu huấn luyện (Training Set Size).



Dựa trên đồ thị, hãy trả lời các câu hỏi sau:

1. Mô tả khoảng cách (gap) giữa hai đường Training Error và Validation Error. Điều này cho biết mô hình đang bị hiện tượng High Bias (Underfitting) hay High Variance (Overfitting)? Hãy giải thích lý do cụ thể dựa trên đồ thị.

2. Tại sao khi kích thước tập dữ liệu huấn luyện tăng lên, Training Error lại tăng nhưng Validation Error lại giảm? Hãy giải thích cơ chế của hiện tượng này.
3. Nếu mục tiêu là giảm khoảng cách giữa hai đường, bạn nên thực hiện giải pháp nào trong 2 giải pháp sau:
 - (A) Thu thập thêm thật nhiều dữ liệu huấn luyện (Data augmentation/Data collection).
 - (B) Sử dụng Regularization (ví dụ: Ridge, Lasso) hoặc đơn giản hóa cấu trúc mô hình (giảm số lượng tham số).

Nêu lý do giải thích cho lựa chọn của bạn dựa trên đồ thị đã cho.

Bài 13: Một kỹ sư đang điều chỉnh tham số cho thuật toán Gradient Descent để hiệu chuẩn cảm biến IMU. Đồ thị dưới đây mô tả 3 kịch bản của Learning Rate (η).

1. Đường A giảm rất chậm, gần như đi ngang. Điều này cho thấy Learning Rate đang quá lớn hay quá nhỏ? Hệ quả về thời gian huấn luyện là gì?
2. Đường B dao động mạnh (oscillation) và cuối cùng Loss tăng vọt lên vô cùng. Giải thích hiện tượng này dưới góc độ toán học.
3. Nếu bạn muốn triển khai tính năng Auto-tuning trên vi điều khiển để tự tìm Learning Rate tối ưu, bạn sẽ dựa vào tín hiệu nào từ đồ thị Loss để quyết định giảm η ?

Bài 14: Giả sử bạn huấn luyện một mô hình Ridge Regression trên tập dữ liệu 1000 mẫu.

- Khi $\lambda = 0.001$: Training Loss = 0.05, Validation Loss = 0.50.
- Khi $\lambda = 10$: Training Loss = 0.15, Validation Loss = 0.18.
- Khi $\lambda = 1000$: Training Loss = 0.80, Validation Loss = 0.82.

1. Hãy nhận xét về trạng thái mô hình (Underfitting, Overfitting hay Just Right) tại mỗi giá trị λ .
2. Giải thích tại sao khi λ tăng, Training Loss lại tăng nhưng mô hình lại có thể tốt hơn cho thực tế?

Bài 15: Trong bài toán hồi quy, tại sao đôi khi người ta ưu tiên sử dụng Huber Loss thay vì MSE (Mean Squared Error) hoặc MAE (Mean Absolute Error)? Hãy viết công thức MSE, MAE, Huber Loss và giải thích cơ chế "chuyển đổi" của nó.

Bài 16: Hãy vẽ phác thảo (hoặc mô tả) hình dáng đồ thị của Huber Loss so với MSE. Tại sao nói Huber Loss kết hợp được ưu điểm của cả MSE và MAE?

Bài 17: Phân biệt L1 Regularization (Lasso) và L2 Regularization (Ridge):

1. Viết hàm mất mát của Linear Regression khi có thêm thành phần L1 và L2.
2. Tại sao Lasso Regression lại có khả năng thực hiện Feature Selection (loại bỏ các đặc trưng không quan trọng) trong khi Ridge Regression thì không?
3. Trong trường hợp dữ liệu có các biến độc lập tương quan mạnh với nhau (Multicollinearity), bạn sẽ ưu tiên dùng Ridge hay Lasso? Tại sao?

Bài 18: Tham số λ (hay alpha trong Scikit-learn) đóng vai trò gì trong Regularization? Điều gì xảy ra với mô hình nếu $\lambda \rightarrow 0$ và khi $\lambda \rightarrow \infty$?

Bài 19: Bạn có một cảm biến áp suất được thu thập dữ liệu qua bộ ADC của vi điều khiển. Do nhiễu điện từ, tập dữ liệu có một vài điểm bị "vọt" (outliers) rất lớn. Nếu dùng OLS thông thường, đường hiệu chuẩn sẽ bị lệch.

1. Khởi tạo một tập dữ liệu giả lập có 50 mẫu theo công thức $y = 3.5x + 10 + \epsilon$,
2. Trong tập dữ liệu vừa tạo, cố tình thay đổi 5 mẫu cuối cùng thành các giá trị nhiễu cực lớn (ví dụ $y = 500$).

3. Sử dụng LinearRegression (OLS) và HuberRegressor từ Scikit-learn để huấn luyện trên cùng tập dữ liệu này.
4. Vẽ đồ thị so sánh hai đường thẳng dự báo của OLS và Huber so với các điểm dữ liệu thực tế.

Bài 20: Bạn đang xây dựng mô hình dự báo tuổi thọ pin của thiết bị Edge AI. Bạn thu thập được 20 tham số đầu vào (nhiệt độ, điện áp, số chu kỳ sạc, cường độ WiFi, tốc độ quạt...). Tuy nhiên, bạn nghi ngờ chỉ có vài tham số thực sự ảnh hưởng. Bạn cần dùng Lasso để "loại bỏ" các tham số thừa nhằm tiết kiệm bộ nhớ cho MCU.

1. Sử dụng bộ dữ liệu `make_regression` của Scikit-learn để tạo 100 mẫu với 20 đặc trưng, nhưng chỉ có 5 đặc trưng là thực sự có ý nghĩa ($n_{informative} = 5$).
2. Sử dụng `StandardScaler` để chuẩn hóa dữ liệu (quan trọng đối với Regularization).
3. Huấn luyện mô hình Lasso với tham số $\alpha=0.1$.
4. In ra các hệ số (w) của mô hình.
5. Vẽ đồ thị so sánh hai đường thẳng dự báo của OLS và Huber so với các điểm dữ liệu thực tế.